Klaudia Wrona Inżynieria Obliczeniowa Numer indeksu: 293128	Podstawy Sztucznej Inteligencji Sprawozdanie nr 3

Poznanie działania reguły Hebba na przykładzie rozpoznawania emotikon.

1. Cel projektu

Celem ćwiczenia jest wygenerowanie danych uczących i testujących, zawierających 4 różne emotikony np. czarnobiałe, wymiar 8x8 pikseli dla jednej emotikony. Przygotowanie sieci oraz reguły Hebba w wersji z i bez współczynnika zapominania. Uczenie sieci dla różnych współczynników uczenia i zapominania. Testowanie sieci.

2. Podstawowe pojęcia

Sieć neuronowa (sztuczna **sieć neuronowa**) – ogólna nazwa struktur matematycznych i ich programowych lub sprzętowych modeli, realizujących obliczenia lub przetwarzanie sygnałów poprzez rzędy elementów, zwanych sztucznymi neuronami, wykonujących pewną podstawową operację na swoim wejściu.

Jest to zbiór neuronów realizujących różne cele. W przypadku sztucznych sieci neuronowych jest to sztuczna struktura zaprojektowana i zbudowana w taki sposób, aby modelowała działanie naturalnego układu nerwowego, a w szczególności mózgu.

Reguła Hebba - Polega na tym, że sieci dostarcza się kolejne przykłady sygnałów wejściowych, nie podając informacji o tym, co z tymi sygnałami należy zrobić.

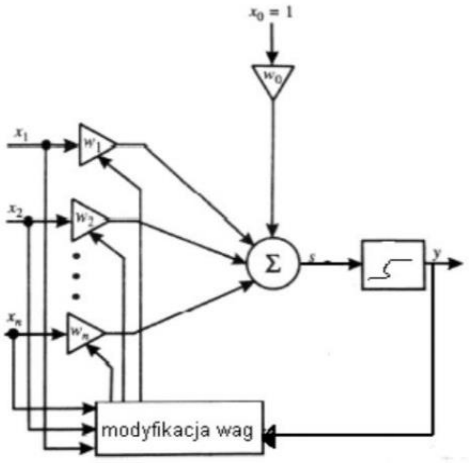

$$w_i(t+1) = w_i(t) + \eta y x_i$$

gdzie:

- i-numer wagi neuronu,
- t-numer iteracji w epoce,
- y-sygnał wyjściowy neuronu,
- x-wartość wejściowa neuronu,
- η - współczynnik uczenia (0,1).

Sieć obserwując otoczenie odbiera różne sygnały, nikt nie określa jednak, jakie znaczenie mają pokazujące się obiekty i jakie są pomiędzy nimi zależności, ponieważ sieć sama określa po czasie jakie jest znaczenie poszczególnych sygnałów. Modyfikację wag przeprowadza się następująco:

Po odczytaniu przez sieć neuronową każdego z zestawów sygnałów wejściowych tworzy się w tej sieci rozkład sygnałów wyjściowych, w którym niektóre neurony sieci są pobudzone bardzo silnie, a inne słabiej.

Niestety ten proces uczenia jest wolniejszy w porównaniu do nauki z nauczycielem. Nie wiadomo również, który neuron będzie rozpoznawał którą klasę neuronów (ważniejszą lub mniej ważną).

Ważne jest, aby dobrze wybrać początkowe wartości wag neuronów.

3. Opis działania

   Wygenerowanie danych uczących – 4 wybranych emotikon.

   Kolor żółty na rysunku pierwszym oznacza jedynki, a biały zera w macierzy reprezentującej emotikony.

   :O

0	0	0	0	0
0	1	0	1	0
0	0	0	0	0
0	1	1	1	0
0	1	1	1	0

   :)

0	0	0	0	0
0	1	0	1	0
0	0	0	0	0
1	0	0	0	1
0	1	1	1	0

   :(

0	0	0	0	0
0	1	0	1	0
0	0	0	0	0
0	1	1	1	0
1	0	0	0	1

   :I

0	0	0	0	0
0	1	0	1	0
0	0	0	0	0
0	1	1	1	0
0	0	0	0	0

   Wygenerowanie danych wejściowych w postaci tabeli „WEJSCIE”, w której każdy wektor (emotikona) zajmował jedną kolumnę.

   Wykorzystanie funkcją ‘newff’ ze zmiennymi parametrami uczenia (epokami, średnim błędem kwadratowym oraz współczynnikiem zapominania jak i współczynnikiem uczenia).

Przeprowadzenie uczenia sieci według zasad Hebba przy zmiennych parametrach oraz w wersji z i bez współczynnika zapominania.

4. Wykonanie zadania i kod

```
close all; clear all; clc;

%wejscia do sieci oraz minimalne oraz maksymalne wartosci
wejsc
%(25 par 0&1 - osobno dla kazdej z danych uczacych)

start=[0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1;
     0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1;
     0 1; 0 1; 0 1; 0 1; 0 1;];

%ilosc wyjsc z sieci (jedna warstwa - 25 neutronow na
wyjsciu)
wyjscia_s = 25;

%uzycie funkcji newff
net = newff(start, wyjscia_s, {'tansig'}, 'trainlm',
'learnh');


 %kolumnowa reprezentacja binarna 4 emotikonow dla tablicy
8x4
             %:):O:(:|
WEJSCIE =  [ 0 0 0 0
             0 0 0 0
             0 0 0 0
             0 0 0 0
             0 0 0 0
             0 0 0 0
             1 1 1 1
             0 0 0 0
             1 1 1 1
             0 0 0 0
             0 0 0 0
             0 0 0 0
             0 0 0 0
             0 0 0 0
             0 0 0 0
             1 0 0 0
             0 1 1 1
             0 1 1 1
             0 1 1 1
             1 0 0 0
             0 0 1 0
             1 1 0 0
             1 1 0 0
```

```
             1 1 0 0
             0 0 1 0
             ];
%zmienna, ktora reprezentuje, czy uzytkownik "trafil" w
wybrana przez
%siebie litere - 1 oznacza trafienie, 0 - chybienie
WYJSCIE = [1 0 0 0 ;  %:)
           0 1 0 0 ;  %:O
           0 0 1 0 ;  %:(
           0 0 0 1 ]; %:|


%PARAMETRY ALGORYTMU HEBBA
% * wspolczynnik zapominania
lp.dr = 0.5;
% * wspolczynnik uczenia
lp.lr = 0.99;

%dostosowanie parametrów sieci do metody Hebba
wagiHebba = learnh([], WEJSCIE, [], [], WYJSCIE, [], [], [],
[], [], lp, []);


%PARAMETRY TRENINGU SIECI:
% * maksymalna ilosc epok
net.trainParam.epochs = 1000;
% * cel wydajnosci sieci
net.trainParam.goal = 0.001;
% * wskaznik uczenia sieci
net.trainParam.lr=0.5;
whebb=wagiHebba';
net = train(net, WEJSCIE, whebb);

%dane testowe
a_testowe= [0;0;0;0;0;
            0;1;0;1;0;
            0;0;0;0;0;
            1;0;0;0;1;
            0;1;1;1;0]; %:)


b_testowe=[0;0;0;0;0;
           0;1;0;1;0;
           0;0;0;0;0;
           0;1;1;1;0;
           0;1;1;1;0;]; %:O



c_testowe=[0;0;0;0;0;
           0;1;0;1;0;
           0;0;0;0;0;
           0;1;1;1;0;
```

```
            1;0;0;0;1;]; %:(

d_testowe=[0;0;0;0;0;
           0;1;0;1;0;
           0;0;0;0;0;
           0;1;1;1;0;
           0;0;0;0;0;]; %:|

efekt = wagiHebba;
%symulacja sieci net
efekt_1 = sim(net, a_testowe);

%wypisywanie wartosci reguly Hebba, wypisywanie kolejnych
wierszy
disp('Jednokrotne wykorzystanie reguly Hebba: ')
disp(':) = '), disp(sum(efekt(1, ':')));
disp(':O = '), disp(sum(efekt(2, ':')));
disp(':( = '), disp(sum(efekt(3, ':')));
disp(':| = '), disp(sum(efekt(4, ':')));


%wypisywanie wartosci
disp('Dzialanie algorytmu z wykorzystaniem r. Hebba dla
emotikon: ')
disp(':) = '), disp(efekt_1(1));
disp(':O = '), disp(efekt_1(2));
disp(':( = '), disp(efekt_1(3));
disp(':| = '), disp(efekt_1(4));
```

5. Wnioski

Reguła Hebba pozawala na uczenie sieci bez nauczyciela. Ze względu na użyty algorytm można zauważyć, że sieć w porównaniu do wcześniejszych metod użytych na zajęciach zdecydowanie potrzebuje więcej czasu na naukę. Przebieg uczenia zależy od wartości początkowych wag.

Reguła Hebba zawiera wiele ograniczeń.

- Nie ma gwarancji, że jednej klasie wzorców będzie odpowiadał jeden neuron
- Nie ma gwarancji, że wszystkie klasy wzorców będą miały oddzielne reprezentacje w postaci oddzielnych zbiorów aktywnych neuronów.

Zmiany wag w dużym stopniu zależą od współczynnika zapominania. Gdy go nie mamy nie ma stabilizacji i wagi mogą rosnąć w nieskończoność

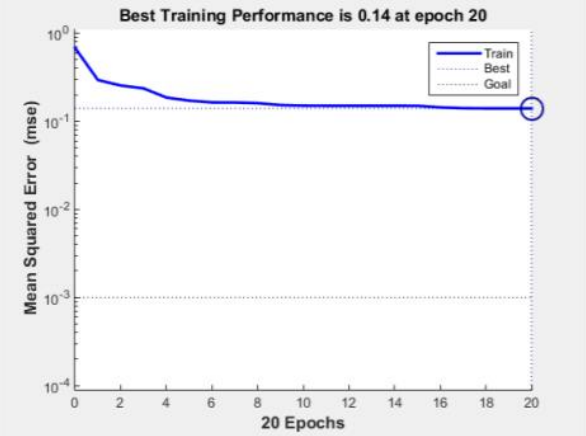

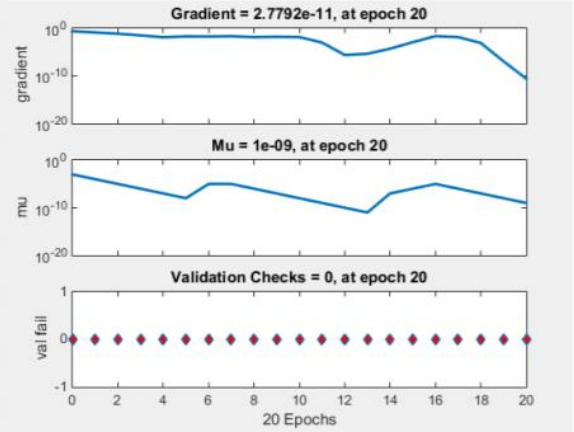

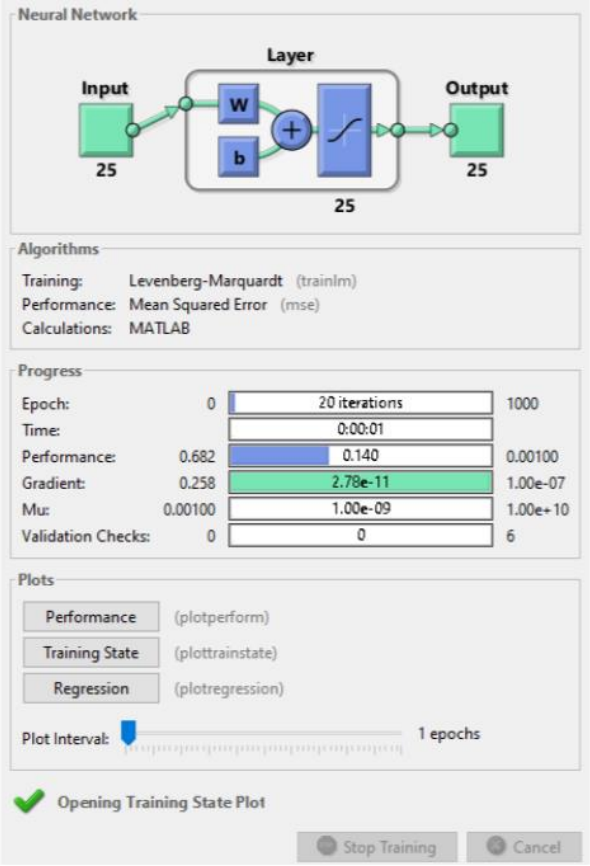

współczynnik zapominania = 0.5
współczynnik uczenia = 0.99
maksymalna ilość epok= 1000
cel wydajności sieci = 0.001
wskaźnik uczenia sieci=0.5